Expérience NGeGenBrain : sondes adaptatives et neurones artificiels

Rapport scientifique complet — exécution confirmatoire et analyses complémentaires

Dossier expérimental NGeGenBrain

28 octobre 2026

Résumé

Ce dossier étudie la relation entre la sonde RBF adaptative dérivée de la formalisation d'observation NGeGenBrain et des neurones artificiels. Il conserve les expériences historiques sur des tâches synthétiques, le diagnostic binaire public et les chiffres manuscrits, puis ajoute une confirmation v1.2 avec de nouvelles graines, une imitation boîte noire de neurones simples et des compositions sous capsules logicielles séparées par rôle. L'audit v1.2 est `PASS_WITH_LIMITATIONS` ; les métriques anciennes v1.1 d'imitation sont explicitement non confirmatoires après découverte d'une exposition du code cible. Les nouvelles expériences montrent une bonne approximation de trois familles de neurones simples sur un domaine borné et un remplacement partiel fonctionnel, mais pas d'équivalence universelle : la fidélité des logits et des activations varie avec la tâche et se dégrade quand plusieurs unités sont remplacées.

Table des matières

1 Résumé exécutif et verdict **3**

2 Analyse des documents sources **3**
2.1 Formalisation NGeGenBrain `full_0` . . . 3
2.2 Expérience antérieure sur deux lunes . . . 3

3 Hypothèses et conditions expérimentales **4**

4 Protocole, données et règle rouge **4**
4.1 Tâches . . . 4
4.2 Partitions et paramètres . . . 4
4.3 Séparation des données et fuites . . . 4

5 Résultats 1 — Apprentissage de tâches **5**
5.1 Lecture . . . 5

6 Résultats 2 — Imitation d'un neurone isolé **6**
6.1 Sensibilité au budget de paramètres — analyse exploratoire . . . 7
6.2 Changement de distribution — analyse exploratoire . . . 8

7 Résultats 3 — Remplacement et composition **8**

8 Résultats 4 — Contrôle de budget final égal (exploratoire) **10**

9 Complément préenregistré – cas réel multiclasse plus exigeant **10**

10 Hypothèses : verdicts circonscrits **12**

11 Limites scientifiques et intégrité **13**

12 Reproductibilité et artefacts **14**

13 Conclusion finale **14**

A Correctif d'intégrité et résultats frais v1.2 **15**
A.1 Correction d'admissibilité des pilotes v1.1 15
A.2 Isolation v1.2 et préenregistrement 15
A.3 Classification sur quatre tâches, partitions fraîches 15
A.4 Imitation boîte noire de neurones isolés 16
A.5 Remplacement et composition de composants 17
A.6 Audit d'intégrité, artefacts et verdict 19

Note de version. Les tableaux historiques des sections précédentes sont conservés sans réécriture des données. Pour toute conclusion exigeant l'isolation logicielle stricte, lire en priorité l'appendice A, qui corrige l'admissibilité des essais v1.1 et donne les résultats frais v1.2.

1 Résumé exécutif et verdict

L'expérience demandée est une étude de la relation entre une sonde adaptative et un neurone, pas une reconstruction de LLM. Elle comporte trois parties complémentaires : apprentissage d'une tâche avec quatre méthodes, imitation de neurones artificiels observés uniquement par leurs entrées/sorties, et composition de sondes en remplacement d'unités cachées d'un réseau source.

— **Classification.** Les sondes adaptatives sont compétitives sur les quatre tâches. La variante à taux d'adaptation méta-appris obtient la meilleure exactitude moyenne sur deux lunes, cercles et cancer du sein ; sur le produit/XOR bruité, elle est comparable aux autres méthodes. Le contrôle fixe est inférieur sur les tâches considérées, mais son nombre de paramètres entraînables est inférieur (17 contre 65 en 2D ou 513 en 30D, et 170 contre 1 210 sur les chiffres) : cette comparaison ne sépare donc pas entièrement adaptation et capacité. Le complément réel à dix classes montre aussi que la RBF adaptative (87.31%) reste sous le MLP (96.76%) et que B à taux méta-appris (78.33%) n'améliore pas A.

— **Imitation isolée.** Avec 256 paires, les sondes RBF à 81 paramètres donnent sur des entrées tenues à part un RMSE moyen d'environ 0.102 sur ReLU, 0.021 sur sigmoïde et 0.050 sur tanh. Le résultat montre l'approximation de neurones simples sur un domaine précis ; il ne prouve pas leur équivalence générale. Les sensibilités au budget de paramètres et au décalage d'entrée sont importantes.

— **Composition.** Le remplacement de 16 unités dans un MLP à 16 unités cachées accroît l'écart de logits moyen jusqu'à environ 0.45 sur deux lunes et 1.44 sur le benchmark réel. L'exactitude peut rester stable ou même augmenter sans que les sorties soient fidèles au modèle source.

— **Intégrité.** L'audit du jeu de données retrouve zéro chevauchement de hachages de lignes entre train/validation/test pour chaque partition, et les interfaces d'ajustement ne prennent pas les labels de test en arguments. Le statut est `PASS_WITH_LIMITATIONS` : l'environnement n'est pas un bac à sable OS adversarial, et l'audit de flux de données n'est pas une preuve absolue d'absence de tout canal caché.

2 Analyse des documents sources

2.1 Formalisation NGeGenBrain `full_0`

La définition utilisée indique qu'une sonde est un opérateur d'observation identifié et versionné, avec domaine, codomaine, procédure d'acquisition, préconditions, budget/coût, niveau d'intrusion, sérialisation et contrôle. L'application d'observation est représentée par $\Phi(p, x, f) \in Y_f$. La théorie insiste aussi sur le contexte, les transformations déclarées, la distinction entre empreinte et dossier d'évidence, et la condition d'injectivité pour une reconstruction exacte. Elle ne définit pas, à elle seule, une sonde comme un réseau apprenant ou comme un neurone.

L'extension de ce rapport est explicitement additive : une sonde paramétrée P_θ adapte ses paramètres selon un signal admissible ; une variante méta-apprend des taux de mise à jour ; une sonde imitatrice apprend une fonction cible uniquement à partir de couples observés $(x, N(x))$. Les définitions et limites sont détaillées dans `formalisme_sonde_adaptative.tex`.

2.2 Expérience antérieure sur deux lunes

Le rapport antérieur comparait 12 sondes RBF adaptatives, un MLP et des sondes fixes sur une seule tâche synthétique, avec cinq initialisations. Il annonçait 96.005% pour les RBF adaptatives, 95.870% pour le MLP, et 86.230% pour le contrôle fixe. Ce résultat motivait le suivi, mais ne testait

ni l'imitation de neurones ni la composition. Il est conservé comme contexte historique, pas combiné aux nouvelles mesures.

3 Hypothèses et conditions expérimentales

Les hypothèses opérationnelles sont : (H1) une sonde adaptative peut apprendre une tâche ; (H2) une sonde peut approximer l'entrée-sortie d'un neurone sans connaître ses paramètres ; (H3) la fidélité peut tenir sur entrées indépendantes ; (H4) des sondes substituées se composent avec une dégradation mesurable ; (H5) les résultats varient selon tâches, budgets et domaine ; (H6) il faut distinguer rôle observationnel, approximation empirique et équivalence mathématique.

Les conditions comparées sont :

1. A — RBF adaptative, paramètres ajustés par Adam sur les labels autorisés ;
2. B — même famille RBF, taux d'actualisation par groupe méta-appris par hypergradient sur train/validation ;
3. contrôle — centres et largeurs RBF fixes, lecture entraînable seulement ;
4. D — MLP de référence à 16 unités tanh ;
5. C1 — imitation entrée-sortie de neuf neurones simples à poids cachés ;
6. C2 — imitation de 16 activations cachées, puis remplacement de 1, 4 ou 16 composants dans deux MLP.

4 Protocole, données et règle rouge

4.1 Tâches

Trois tâches synthétiques sont générées de manière déterministe : deux lunes, cercles concentriques et classification du signe du produit $x_1 x_2$ avec 4% de bruit de label. Les cas réels sont le dataset public Wisconsin Diagnostic Breast Cancer fourni par scikit-learn (569 exemples, 30 variables) et, dans le complément préenregistré, le jeu de chiffres manuscrits scikit-learn (1 797 images 8×8, 64 variables, 10 classes). Ce sont des benchmarks compacts ; le premier n'est pas une validation clinique et le second n'est pas une validation en production.

4.2 Partitions et paramètres

Les données sont réparties stratifié en 60% entraînement, 20% validation et 20% test. Les graines confirmatoires sont 714, 825 et 936. Le standardiseur n'est ajusté que sur train (60%). Les modèles finaux de classification sont réajustés sur train+validation ; le jeu de test n'entre pas dans l'ajustement. Sur les données synthétiques, la partition compte 1080/360/360 exemples ; sur le benchmark réel, 341/114/114.

La sonde RBF de classification a 16 centres et exactement le même nombre de paramètres entraînables que le MLP correspondant : 65 en dimension 2 et 513 en dimension 30. Le contrôle fixe n'a que 17 paramètres entraînables. La condition B apprend quatre taux par groupe à partir d'épisodes de train/validation puis entraîne 700 époques ; A, le contrôle et le MLP sont entraînés 220 époques dans l'analyse principale. Pour traiter ce déséquilibre de budget, une analyse secondaire à 700 époques finales pour les quatre méthodes est rapportée séparément.

4.3 Séparation des données et fuites

Pour l'imitation isolée, la sonde reçoit uniquement les observations (x_i, y_i) interrogées sur la cible. Ni la famille d'activation, ni la graine/les paramètres du neurone cible, ni les sorties de test ne sont des arguments de la fonction d'ajustement. Les graines des sondes (111, 222, 333) sont indépendantes des neuf graines des cibles (107, 110, 113, 208, 211, 214, 309, 312, 315). Pour la composition, les sondeurs reçoivent l'entrée et les activations cachées observées seulement sur train ; les activations de test servent à calculer les métriques une fois les sondes gelées.

L'audit recalcule les hachages des lignes brutes par tâche/partition et obtient zéro chevauchement de hachages entre train, validation et test, pour 17 907 enregistrements de partition. Les interfaces d'ajustement ont été inspectées et les prédictions sont reproductibles octet par octet lors d'une relance par étapes. Limite importante : l'exécution a lieu dans un orchestrateur local et non dans un bac à sable résistant à un processus hostile ayant accès arbitraire au système de fichiers ; aucune affirmation d'absence absolue de canaux cachés n'est faite.

Le protocole version 1.1 a été haché avant l'exécution confirmatoire indépendante. L'audit a détecté que la première composition utilisait par erreur les graines de classification 714/825/936 au lieu des graines de composition spécifiées 411/522/633. Ces lots déviants sont conservés sous audit, exclus des synthèses et remplacés par six lots exécutés après gel du correctif v1.2. Les analyses sur décalage de distribution, budget de paramètres et époques égales sont des extensions exploratoires ajoutées après l'analyse principale et identifiées comme telles.

5 Résultats 1 — Apprentissage de tâches

Les nombres sont des moyennes ± écarts-types sur trois partitions/graines distinctes. Le petit nombre de graines implique des intervalles de confiance larges ; il ne permet pas de déclarer une supériorité universelle.

Méthode	Exactitude %	F1 %	ROC-AUC	Log-loss	Param.
Sonde RBF fixe	85.37 ± 1.16	85.21 ± 0.93	0.9260 ± 0.0060	0.351 ± 0.012	17
Sonde RBF adaptative	93.61 ± 0.56	93.59 ± 0.63	0.9794 ± 0.0045	0.204 ± 0.018	65
Sonde à mécanisme partiellement appris	95.74 ± 0.58	95.76 ± 0.55	0.9899 ± 0.0031	0.127 ± 0.010	65
MLP de référence	90.74 ± 2.52	90.67 ± 2.64	0.9673 ± 0.0184	0.233 ± 0.060	65

TABLE 1 – Classification sur Deux lunes. Moyenne ± écart-type sur trois partitions/graines distinctes. Les écarts-types de l'exactitude et du F1 sont en points de pourcentage.

Méthode	Exactitude %	F1 %	ROC-AUC	Log-loss	Param.
Sonde RBF fixe	90.56 ± 1.11	91.20 ± 0.95	0.9774 ± 0.0040	0.403 ± 0.034	17
Sonde RBF adaptative	94.35 ± 0.89	94.34 ± 0.88	0.9898 ± 0.0036	0.151 ± 0.015	65
Sonde à mécanisme partiellement appris	94.72 ± 1.11	94.72 ± 1.12	0.9901 ± 0.0034	0.130 ± 0.020	65
MLP de référence	94.44 ± 1.21	94.41 ± 1.20	0.9887 ± 0.0035	0.156 ± 0.017	65

TABLE 2 – Classification sur Cercles. Moyenne ± écart-type sur trois partitions/graines distinctes. Les écarts-types de l'exactitude et du F1 sont en points de pourcentage.

Méthode	Exactitude %	F1 %	ROC-AUC	Log-loss	Param.
Sonde RBF fixe	91.85 ± 1.85	92.10 ± 1.71	0.9461 ± 0.0026	0.435 ± 0.007	17
Sonde RBF adaptative	94.17 ± 0.48	94.32 ± 0.41	0.9490 ± 0.0017	0.287 ± 0.005	65
Sonde à mécanisme partiellement appris	93.80 ± 1.12	93.97 ± 1.00	0.9487 ± 0.0016	0.280 ± 0.008	65
MLP de référence	94.26 ± 0.42	94.40 ± 0.33	0.9530 ± 0.0034	0.261 ± 0.006	65

TABLE 3 – Classification sur Produit/XOR bruité. Moyenne ± écart-type sur trois partitions/graines distinctes. Les écarts-types de l'exactitude et du F1 sont en points de pourcentage.

5.1 Lecture

Sur deux lunes, B atteint environ 95.74% d'exactitude contre 93.61% pour A, 90.74% pour le MLP et 85.37% pour le contrôle fixe. Sur les cercles, les méthodes adaptatives sont très proches, tandis

Méthode	Exactitude %	F1 %	ROC-AUC	Log-loss	Param.
Sonde RBF fixe	91.81 ± 1.34	93.73 ± 0.92	0.9821 ± 0.0121	0.244 ± 0.055	17
Sonde RBF adaptative	96.49 ± 1.52	97.25 ± 1.18	0.9942 ± 0.0070	0.132 ± 0.025	513
Sonde à mécanisme partiellement appris	98.25 ± 0.88	98.61 ± 0.70	0.9947 ± 0.0078	0.088 ± 0.034	513
MLP de référence	97.95 ± 1.01	98.38 ± 0.80	0.9926 ± 0.0078	0.087 ± 0.052	513

TABLE 4 – Classification sur Cancer du sein (benchmark). Moyenne ± écart-type sur trois partitions/graines distinctes. Les écarts-types de l'exactitude et du F1 sont en points de pourcentage.

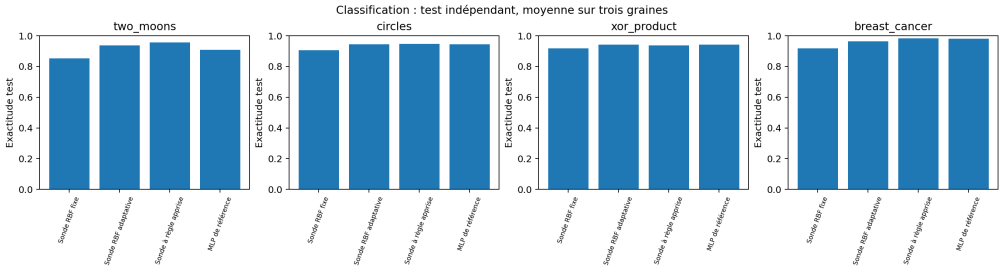


FIGURE 1 – Exactitude moyenne par tâche et méthode. Les trois graines sont montrées dans les tables précédentes ; le graphique synthétise seulement les tendances.

que la sonde fixe est plus faible. Sur le produit/XOR bruité, les quatre méthodes sont assez proches entre elles, avec le MLP à environ 94.26%, A à 94.17%, B à 93.80% et la sonde fixe à 91.85%. Sur le benchmark réel, B est à 98.25%, le MLP à 97.95%, A à 96.49% et le contrôle fixe à 91.81%.

Ces résultats soutiennent H1 : les sondes adaptatives apprennent bien ces tâches sous les budgets considérés. Les résultats du contrôle fixe sont compatibles avec l'utilité des degrés de liberté adaptatifs, mais le contrôle fixe a moins de paramètres, donc l'expérience n'isole pas parfaitement l'effet de l'adaptation.

6 Résultats 2 — Imitation d'un neurone isolé

Neuf neurones cibles boîte noire sont étudiés : trois avec activation tanh, trois ReLU et trois sigmoïde. Les sondes reçoivent 64, 256 ou 1024 paires de requêtes. Le test comporte 4000 entrées indépendantes dans la même distribution uniforme que l'apprentissage. L'activation cible est une métadonnée de l'évaluateur et n'est pas fournie à la fonction d'ajustement.

Activation cible (évaluateur seulement)	Paires observées	MAE	RMSE	R^2
tanh	64	0.0482 ± 0.0312	0.0718 ± 0.0436	0.9898 ± 0.0081
tanh	256	0.0382 ± 0.0215	0.0501 ± 0.0264	0.9951 ± 0.0031
tanh	1024	0.0324 ± 0.0171	0.0427 ± 0.0218	0.9963 ± 0.0022
relu	64	0.0806 ± 0.0281	0.1152 ± 0.0290	0.9887 ± 0.0031
relu	256	0.0715 ± 0.0386	0.1015 ± 0.0599	0.9926 ± 0.0024
relu	1024	0.0676 ± 0.0362	0.0929 ± 0.0459	0.9936 ± 0.0010
sigmoid	64	0.0166 ± 0.0032	0.0234 ± 0.0038	0.9807 ± 0.0253
sigmoid	256	0.0159 ± 0.0042	0.0207 ± 0.0042	0.9869 ± 0.0161
sigmoid	1024	0.0157 ± 0.0047	0.0200 ± 0.0052	0.9889 ± 0.0127

TABLE 5 – Imitation en boîte noire : moyennes sur trois cibles indépendantes par famille, après moyenne sur trois initialisations de sonde. La formule et les paramètres de chaque cible ne sont pas des entrées de la fonction d'ajustement.

Sur 256 observations, le RMSE moyen entre cibles vaut environ 0.102 sur ReLU, 0.021 sur sigmoïde et 0.050 sur tanh. Le score R^2 est élevé sur la distribution tenue à part. Cela soutient H2 dans cette

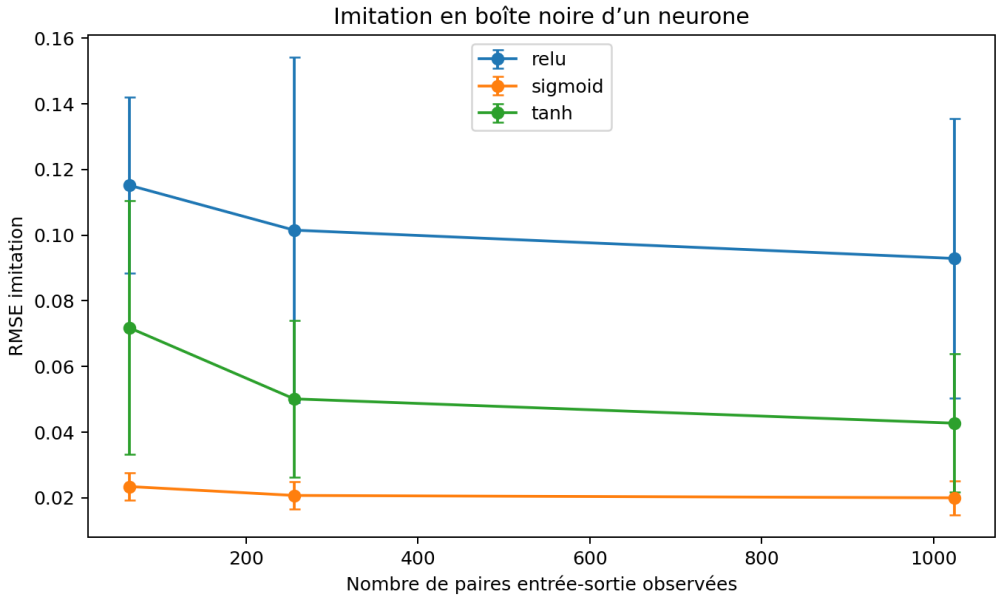


FIGURE 2 – Fidélité d'imitation selon le nombre de paires entrée-sortie autorisées.

famille très restreinte : une sonde RBF peut approximer la fonction entrée-sortie de certains neurones simples à partir d'observations.

6.1 Sensibilité au budget de paramètres — analyse exploratoire

Le neurone cible affine+activation en dimension 2 n'a que trois paramètres continus (w_1, w_2, b). La sonde RBF à 20 centres a 81 paramètres ; le résultat primaire ne saurait donc être interprété comme une égalité de capacité.

Famille cible	Centres RBF	Paramètres sonde	RMSE	R^2
tanh	1	5	0.2851 ± 0.1197	0.8433 ± 0.0743
tanh	2	9	0.1649 ± 0.0893	0.9474 ± 0.0364
tanh	4	17	0.1238 ± 0.0696	0.9699 ± 0.0222
tanh	8	33	0.0786 ± 0.0505	0.9875 ± 0.0106
tanh	20	81	0.0501 ± 0.0264	0.9951 ± 0.0031
relu	1	5	0.6888 ± 0.3785	0.6544 ± 0.0858
relu	2	9	0.5260 ± 0.3382	0.8008 ± 0.0917
relu	4	17	0.3109 ± 0.1426	0.9256 ± 0.0145
relu	8	33	0.1837 ± 0.0943	0.9745 ± 0.0054
relu	20	81	0.1015 ± 0.0599	0.9926 ± 0.0024
sigmoid	1	5	0.1048 ± 0.0443	0.8004 ± 0.1331
sigmoid	2	9	0.0674 ± 0.0253	0.9081 ± 0.0678
sigmoid	4	17	0.0473 ± 0.0144	0.9467 ± 0.0529
sigmoid	8	33	0.0327 ± 0.0079	0.9680 ± 0.0379
sigmoid	20	81	0.0207 ± 0.0042	0.9869 ± 0.0161

TABLE 6 – Analyse secondaire de capacité à budget d'observation fixé à 256 paires. Un neurone cible affine+activation possède trois paramètres continus en 2D. Les sondes utilisent 5 à 81 paramètres selon le nombre de centres.

Le RMSE baisse généralement avec le nombre de centres, mais le coût en paramètres croît de 5 à 81. Avec un seul centre, R^2 est nettement moins élevé, notamment sur ReLU ; cette ablation rend explicite le rôle de capacité. Elle ne compare pas encore toutes les familles de sonde ni les modèles à budget exactement égal.

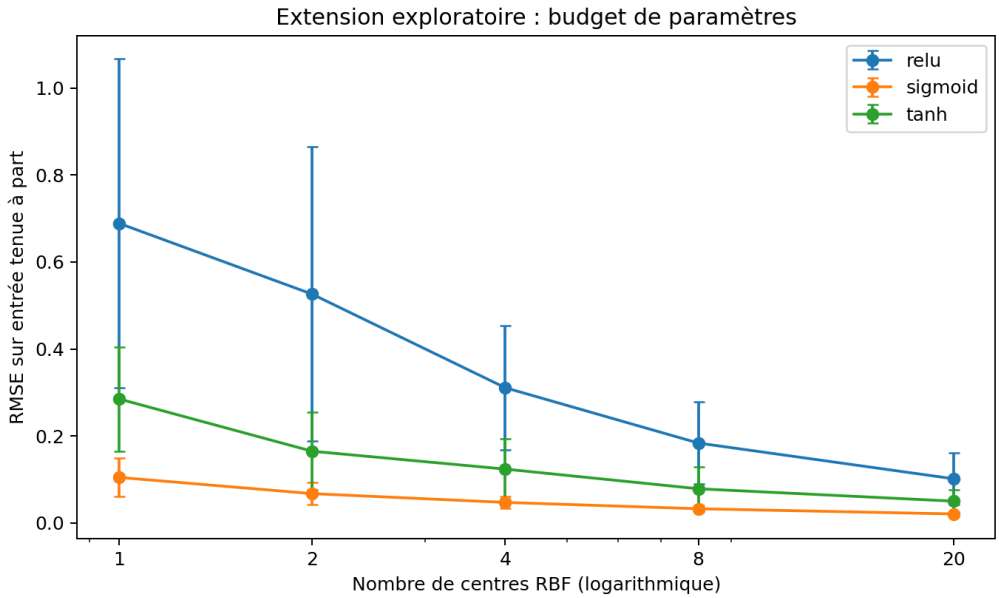


FIGURE 3 – Analyse exploratoire : relation entre budget paramétrique de la sonde et erreur d'imitation.

6.2 Changement de distribution — analyse exploratoire

Les sondes sont entraînées sur des entrées uniformes dans $[-2.5, 2.5]^2$, puis évaluées sur une distribution translatée de $(+1.5, -1.5)$, sans réentraînement.

Famille cible	Paires	RMSE in-domain	RMSE entrée décalée	R^2 décalé
tanh	64	0.0718	0.1719	0.749
tanh	256	0.0501	0.2173	0.540
tanh	1024	0.0427	0.1792	0.732
relu	64	0.1152	0.8308	0.260
relu	256	0.1015	0.7651	0.317
relu	1024	0.0929	0.7149	0.183
sigmoid	64	0.0234	0.1659	-0.320
sigmoid	256	0.0207	0.1544	0.091
sigmoid	1024	0.0200	0.1386	0.271

TABLE 7 – Analyse secondaire exploratoire. La distribution d'évaluation est translatée de (+1.5, -1.5), sans réentraînement ni choix d'hyperparamètres sur ces entrées.

Le RMSE augmente fortement hors distribution. Pour ReLU, il passe approximativement de 0.093 à 0.715 avec 1024 observations ; pour tanh, de 0.043 à 0.179 ; pour sigmoïde, de 0.020 à 0.139. H3 n'est donc pas soutenue comme propriété générale : une bonne fidélité in-domain ne garantit pas une bonne extrapolation.

7 Résultats 3 — Remplacement et composition

La composition est testée sur deux lunes et le benchmark de diagnostic. Un MLP source à 16 unités cachées est entraîné sur le sous-ensemble train. Pour chaque unité cachée, une sonde scalaire reçoit les paires entrée/activation observée sur train. À l'évaluation, les activations des premières unités sont substituées par les prédictions des sondes, tandis que le lecteur de sortie original est gardé.

La composition v1.2 utilise les graines prévues 411/522/633. Sur deux lunes, la précision moyenne du MLP enseignant est 92.87% ; le remplacement de 1, 4 et 16 unités donne respectivement 92.96%, 92.41% et 88.52%, avec un écart absolu moyen de logits de 0.016, 0.089 et 0.469. Sur le benchmark public, la précision enseignante est 97.66% et le remplacement de 1, 4 et 16 unités donne 97.95%,

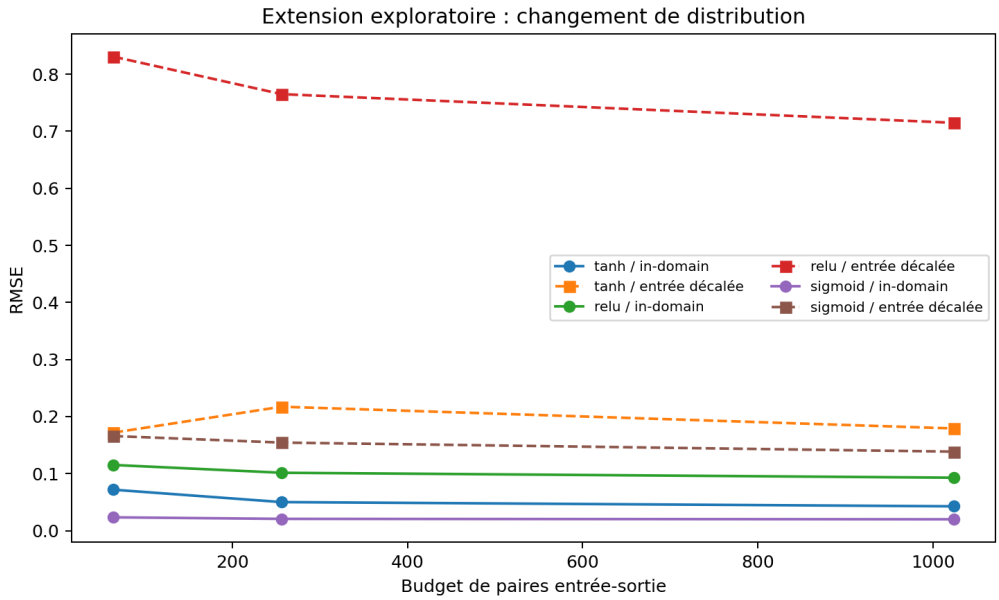


FIGURE 4 – Analyse exploratoire de généralisation sous un décalage de distribution.

Tâche	MAE activation	RMSE activation	R^2 activation
Deux lunes	0.0531 ± 0.0089	0.0694 ± 0.0108	0.9820 ± 0.0043
Cancer du sein (benchmark)	0.2478 ± 0.0194	0.3153 ± 0.0239	0.8654 ± 0.0257

TABLE 8 – Fidélité de 16 sondes RBF sur les activations cachées du MLP, moyenne sur neurones puis sur trois graines. Les sondes ont 49 paramètres chacun en 2D et 257 en 30D ; un neurone du MLP a 3 paramètres d'entrée pour la tâche 2D ou 31 en 30D.

Tâche	Unités	MLP exact. %	Après %	Écart logits
Deux lunes	1	92.87 ± 2.05	92.96 ± 1.89	0.016 ± 0.001
Deux lunes	4	92.87 ± 2.05	92.41 ± 1.85	0.089 ± 0.051
Deux lunes	16	92.87 ± 2.05	88.52 ± 1.43	0.469 ± 0.164
Cancer du sein (benchmark)	1	97.66 ± 1.01	97.95 ± 0.51	0.133 ± 0.025
Cancer du sein (benchmark)	4	97.66 ± 1.01	98.25 ± 0.88	0.454 ± 0.046
Cancer du sein (benchmark)	16	97.66 ± 1.01	98.83 ± 1.01	1.596 ± 0.042

TABLE 9 – Substitution de composants. La lecture de sortie du MLP enseignant est conservée. La différence de logits est une mesure de fidélité comportementale ; l'exactitude peut rester stable malgré cette différence.

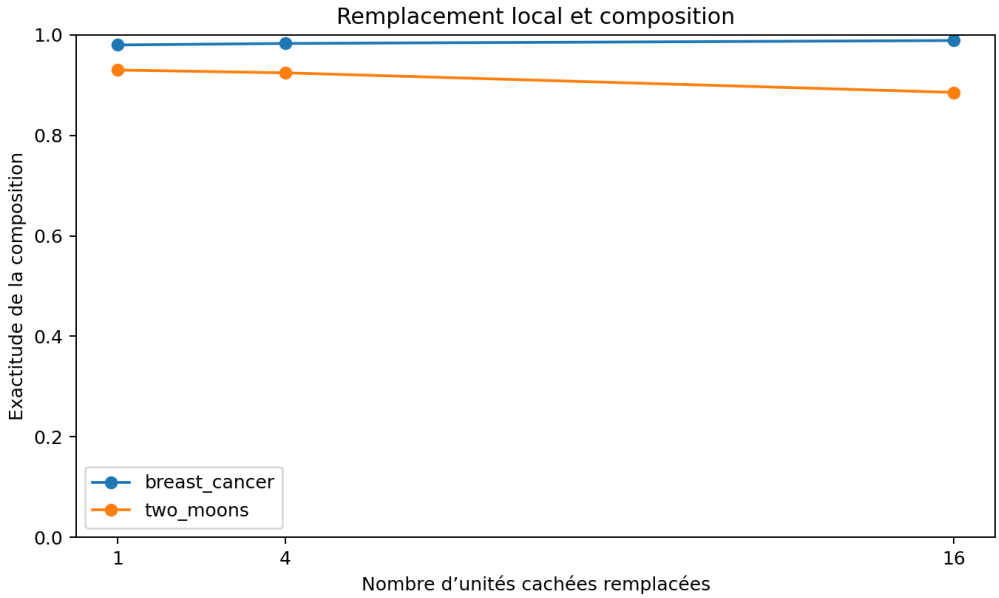


FIGURE 5 – Exactitude après remplacement de 1, 4 ou 16 unités cachées dans la composition. La variation des logits est rapportée séparément.

98.25% et 98.83%, alors que l'écart moyen de logits croît de 0.133 à 0.454 puis 1.596. Cette divergence montre que l'exactitude de classe peut masquer une fidélité réduite au système source. Le nombre d'unités remplacées constitue une intervention de composition contrôlée.

La composition conserve le lecteur de sortie original ; elle n'est donc pas un étudiant autonome. La conclusion correcte est plus étroite : des sondes peuvent remplacer certains composants localement, mais les erreurs changent la sortie composée et s'accumulent. H4 n'est que partiellement soutenue et dépend de la tâche et de la métrique.

8 Résultats 4 — Contrôle de budget final égal (exploratoire)

B bénéficie dans l'analyse principale de 700 époques finales, contre 220 pour A et le MLP. Le tableau suivant compare les modèles après 700 époques finales ; B conserve le coût de 35 étapes d'hypergradient en amont. Il s'agit d'un contrôle exploratoire, pas d'une égalité totale de temps de calcul.

Sous 700 époques finales, A et B sont très proches sur le benchmark réel (environ 98.25% tous les deux), sur deux lunes (95.74% tous les deux), sur les cercles (94.35% contre 94.72%) et sur le produit/XOR (93.43% contre 93.80%). Le bénéfice apparent de B dans la comparaison principale se réduit donc une fois le nombre d'époques d'A augmenté. Il ne faut pas attribuer l'écart principal au seul fait que le mécanisme de sonde aurait été « appris ».

9 Complément préenregistré – cas réel multiclasse plus exigeant

Le benchmark binaire de diagnostic public de l'expérience primaire est réel mais petit. Pour tester le protocole sur un cas d'usage réel plus riche, un complément distinct a été préenregistré avant exécution. Il utilise le jeu public de chiffres manuscrits de scikit-learn : 1 797 images 8×8, 64 entrées par image et dix classes. Les partitions sont les graines 1428, 2539 et 3640, stratifiées en 60/20/20 ; le standardiseur est ajusté sur train seulement. Ce jeu est un benchmark de laboratoire compact, non une validation de reconnaissance d'écriture en production.

Sur ces trois partitions, la RBF adaptative A atteint 87.31% d'exactitude moyenne ; la variante B dont les taux de mise à jour sont méta-appris atteint 78.33% ; la RBF fixe atteint 76.67% ; le MLP avec capacité paramétrique égale à A/B (1 210 paramètres chacun) atteint 96.76%. Sur ce cas réel multiclasse, le mécanisme d'adaptation méta-appris ne donne donc pas de gain observé : B est

Tâche	Méthode	Exactitude %	ROC-AUC	Log-loss
Deux lunes	RBF adaptative	95.74 ± 0.58	0.9894 ± 0.0031	0.130 ± 0.009
Deux lunes	RBF règle/taux appris	95.74 ± 0.58	0.9899 ± 0.0031	0.127 ± 0.010
Deux lunes	RBF fixe	86.94 ± 1.44	0.9335 ± 0.0084	0.332 ± 0.016
Deux lunes	MLP	95.65 ± 0.70	0.9895 ± 0.0027	0.129 ± 0.008
Cercles	RBF adaptative	94.35 ± 0.89	0.9894 ± 0.0030	0.132 ± 0.017
Cercles	RBF règle/taux appris	94.72 ± 1.11	0.9901 ± 0.0034	0.130 ± 0.020
Cercles	RBF fixe	92.96 ± 0.42	0.9851 ± 0.0015	0.235 ± 0.021
Cercles	MLP	94.35 ± 0.98	0.9884 ± 0.0031	0.139 ± 0.019
Produit/XOR bruité	RBF adaptative	93.43 ± 0.70	0.9478 ± 0.0033	0.275 ± 0.010
Produit/XOR bruité	RBF règle/taux appris	93.80 ± 1.12	0.9487 ± 0.0016	0.280 ± 0.008
Produit/XOR bruité	RBF fixe	93.06 ± 0.00	0.9498 ± 0.0026	0.335 ± 0.001
Produit/XOR bruité	MLP	94.35 ± 0.16	0.9464 ± 0.0031	0.244 ± 0.003
Cancer du sein (benchmark)	RBF adaptative	98.25 ± 0.88	0.9947 ± 0.0078	0.093 ± 0.033
Cancer du sein (benchmark)	RBF règle/taux appris	98.25 ± 0.88	0.9947 ± 0.0078	0.088 ± 0.034
Cancer du sein (benchmark)	RBF fixe	94.15 ± 1.34	0.9890 ± 0.0062	0.156 ± 0.026
Cancer du sein (benchmark)	MLP	96.78 ± 0.51	0.9891 ± 0.0099	0.124 ± 0.079

TABLE 10 – Analyse secondaire exploratoire : tous les modèles reçoivent 700 époques finales. B conserve en plus 35 étapes de méta-ajustement. Ce tableau teste si l'écart principal dépend seulement des époques ; il ne constitue pas un contrôle strict à budget total de calcul égal.

Méthode	Exactitude (%)	Balanced acc. (%)	F1 macro (%)	Log-loss	Param.
Sonde RBF fixe	76.67 ± 3.38	76.66 ± 3.38	76.48 ± 3.37	1.304 ± 0.004	170
Sonde RBF adaptative	87.31 ± 3.52	87.34 ± 3.49	87.34 ± 3.45	0.752 ± 0.055	1210
Sonde à mécanisme partiellement appris	78.33 ± 2.27	78.28 ± 2.22	78.00 ± 2.11	1.419 ± 0.026	1210
MLP de référence	96.76 ± 1.16	96.77 ± 1.16	96.77 ± 1.16	0.126 ± 0.032	1210

TABLE 11 – Reconnaissance réelle de chiffres manuscrits à dix classes : images 8×8, 64 entrées, trois partitions prédéfinies. Moyenne ± écart-type sur trois graines. A, B et le MLP disposent chacun de 1 210 paramètres entraînables ; le contrôle RBF fixe de 170.

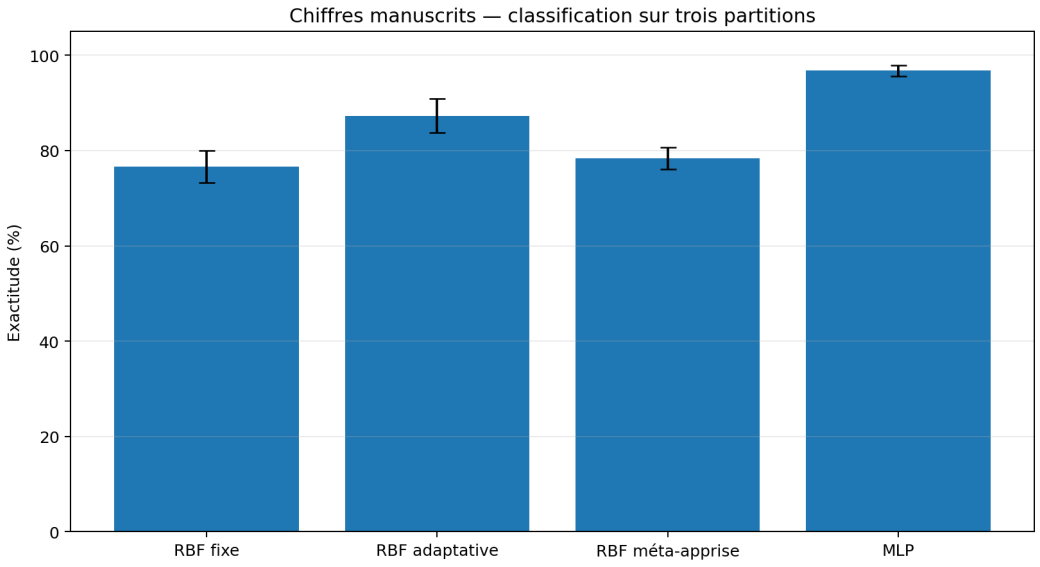


FIGURE 6 – Exactitude des quatre méthodes sur le benchmark réel à dix classes ; les barres d'erreur indiquent l'écart-type sur trois partitions.

nettement moins performante que A et que le MLP. Ce résultat négatif est conservé sans ajustement a posteriori. Trois partitions seulement imposent une incertitude importante.

Unités remplacées	MLP source (%)	Composé (%)	Accord source (%)	RMSE logits	Écart prob.
1	96.76 ± 1.16	96.11 ± 1.00	99.17 ± 0.00	0.389 ± 0.023	0.0033 ± 0.0005
4	96.76 ± 1.16	95.74 ± 1.28	98.15 ± 1.05	0.783 ± 0.022	0.0084 ± 0.0012
16	96.76 ± 1.16	86.57 ± 1.95	86.94 ± 2.82	1.878 ± 0.023	0.0547 ± 0.0027

TABLE 12 – Substitution de 1, 4 ou 16 unités cachées sur la reconnaissance manuscrite. Le lecteur de sortie du MLP source est conservé ; il ne s'agit pas d'un modèle étudiant autonome. Moyenne ± écart-type sur trois partitions.

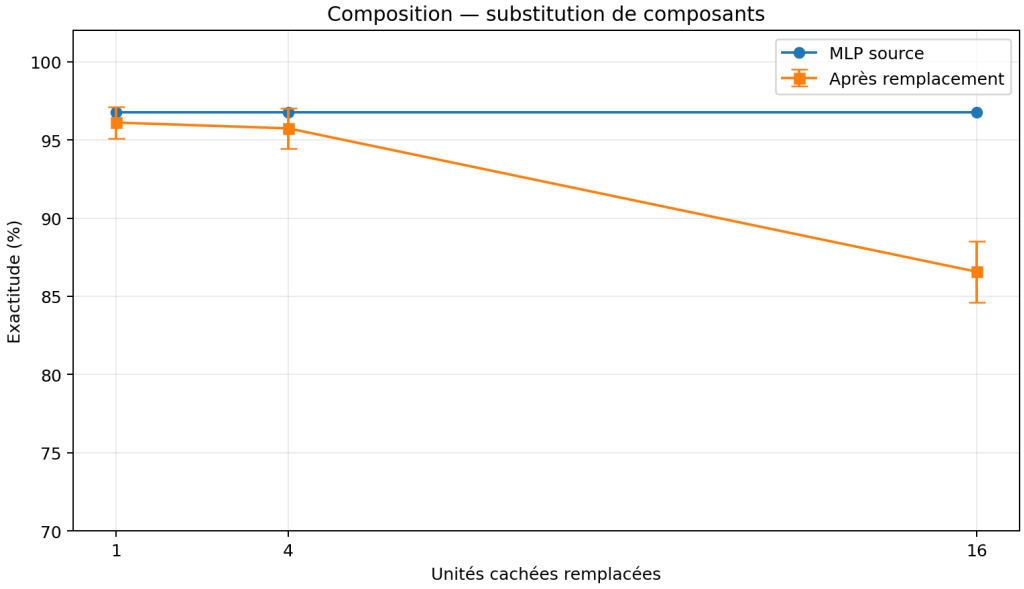


FIGURE 7 – Exactitude du MLP source et du système après remplacement d'unités cachées.

La fidélité des sondes scalaires aux activations cachées du MLP a un RMSE moyen de 0.5218 au test (RMSE d'entraînement moyen 0.5184). Chaque sonde utilisée pour imiter une unité cachée comporte 529 paramètres entraînables, alors qu'une unité cachée du MLP 64→16 possède 65 paramètres affines. La sonde a donc un budget de paramètres nettement supérieur ; ces résultats ne montrent pas une équivalence à capacité égale.

Le remplacement d'une ou quatre unités conserve une exactitude proche de celle de la source, mais l'écart des logits augmente. Le remplacement des 16 unités fait baisser l'exactitude composée moyenne à 86.57%, contre 96.76% pour le MLP source, et l'accord des classes source/composé à 86.94%. Les erreurs locales peuvent donc s'accumuler lors de la composition. Le lecteur de sortie original est maintenu : il ne s'agit pas d'une reconstruction autonome.

Les prédictions gelées, matrices de confusion par méthode/split, fidélités par unité, intervalles t descriptifs à 95% (`digits_synthese_intervalles_95.csv` et `digits_composition_intervalles_95.csv`), registre des partitions et empreintes sont fournis dans les CSV et JSON associés. Les labels du test ne sont pas des arguments des fonctions d'entraînement.

10 Hypothèses : verdicts circonscrits

H1 — Apprentissage de tâche :
soutenue dans les tâches testées, mais avec des performances variables selon le domaine : sur les chiffres manuscrits, la RBF adaptative reste sous le MLP. Le contrôle fixe est plus faible, mais son budget de paramètres est moindre.

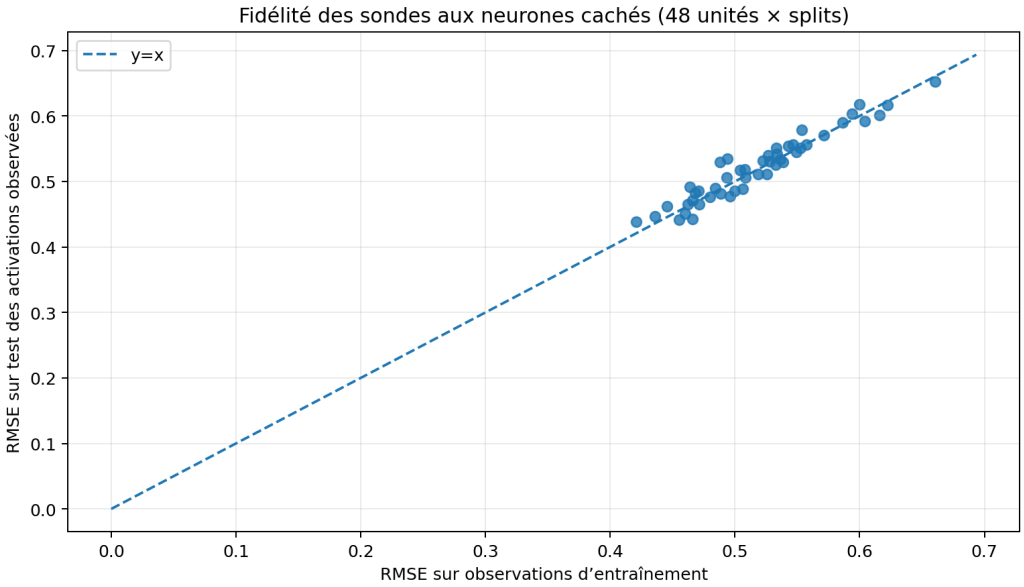


FIGURE 8 – RMSE sur les activations de train et de test pour les 48 sondes imitant les unités cachées.

H2 — Imitation de neurones :
soutenue pour une famille artificielle limitée de neurones scalaires, grâce à des exemples entrée-sortie autorisés, dans le domaine in-domain testé.

H3 — Généralisation :
soutenue partiellement sur une partition iid tenue à part ; contredite comme affirmation robuste sous le décalage d'entrée exploratoire. Les interventions plus générales ne sont pas couvertes.

H4 — Composition :
partiellement soutenue. Le remplacement local est réalisable, mais la fidélité de logits décroît nettement quand plus d'unités sont remplacées, et l'exactitude finale dépend de la tâche.

H5 — Généralité :
non établie. Cinq tâches de classification, dont trois synthétiques et deux benchmarks réels compacts, et trois partitions par tâche constituent un échantillon limité.

H6 — Neurone cas particulier de sonde :
les résultats sont compatibles avec une interprétation opérationnelle et une capacité d'approximation ; ils ne démontrent pas une équivalence mathématique universelle.

11 Limites scientifiques et intégrité

1. **Capacité.** Les sondes d'imitation à 20 centres sont beaucoup plus paramétriques que le neurone isolé ; l'analyse exploratoire confirme que le nombre de paramètres contribue au score.
2. **Famille d'activation.** L'expérience boîte noire ne couvre que trois activations simples et des cibles affines en deux dimensions. Cela ne représente pas toutes les unités modernes, les normalisations, les états contextuels ou les dynamiques temporelles.
3. **Mécanisme appris.** La condition B apprend des taux par groupe ; elle conserve la RBF et le type de mise à jour prédéfinis. Ce n'est pas un optimiseur découvert de novo. Les hypergradients utilisent la validation autorisée.
4. **Comparabilité du calcul.** Les époques principales de B sont plus nombreuses que celles d'A/D ; le contrôle 700 époques est présenté séparément et montre que l'avantage se réduit.
5. **Compositions.** Le lecteur de sortie source est conservé. Nous ne démontrons donc pas un modèle autonome complet construit uniquement par sondes.

6. **Données réelles.** Les deux benchmarks réels sont compacts : le jeu de diagnostic n'est pas une validation clinique et les chiffres manuscrits ne sont pas un test de reconnaissance en production.
7. **Statistique.** Trois partitions/graines imposent une incertitude importante. Les intervalles t fournis sont descriptifs ; ils ne prouvent ni une supériorité générale ni une réplication indépendante multi-site.
8. **Anti-triche.** Les interfaces d'ajustement n'acceptent pas les labels de test ni les paramètres cibles, les graines d'imitation sont indépendantes et les hachages des lignes sont disjoints dans chaque partition. L'audit ne garantit pas contre tout canal covert possible dans un même environnement local.
9. **Préenregistrement.** Les résultats primaires utilisent le protocole v1.1 gelé avant exécution ; la composition suit le correctif v1.2 gelé avant relance ; la reconnaissance de chiffres suit un protocole complémentaire gelé avant son exécution. Les essais de mise au point antérieurs sont exclus. Les analyses de budget de paramètres, décalage d'entrée et époques égales sont explicitement exploratoires et postérieures au résultat primaire.
10. **Traçabilité administrative.** Le finaliseur utilisé pour les agrégats et le manifeste a été retouché après l'exécution pour séparer les graines de classification et de composition. Son empreinte actuelle diffère de l'empreinte pré-exécution ; cette divergence est décrite dans le journal d'audit. Le code d'entraînement et le lanceur de composition restent conformes aux empreintes gelées.

12 Reproductibilité et artefacts

Le pipeline est CPU-only et utilise Python, PyTorch, NumPy, pandas, scikit-learn, SciPy et Matplotlib. Les données synthétiques sont générées par scripts ; le jeu réel est obtenu par la fonction de chargement standard du jeu de données de scikit-learn. Les prédictions d'évaluation sont enregistrées dans `predictions_test_apres_gel.csv` après gel du modèle.

L'audit final est `PASS_WITH_LIMITATIONS`, avec 12 contrôles passés et une limitation de sandbox explicitement déclarée. Le registre d'intégrité et les empreintes sont inclus dans l'archive.

Commandes détaillées de reproduction, versions et limitations sont dans `README.md`. Les résultats par graine, intervalles, traces des cibles, métriques par neurone et compositions sont fournis en CSV et JSON ; l'archive de reproductibilité contient aussi le code et les deux documents source utilisés.

13 Conclusion finale

Cette expérience apporte des résultats empiriques ciblés : une famille de sondes adaptatives peut apprendre certaines tâches, imiter par observation certains neurones artificiels simples et être insérée à leur place dans des compositions. Le complément réel multiclasse montre cependant que la RBF adaptative reste nettement derrière le MLP sur les chiffres manuscrits, et que la variante à mécanisme partiellement appris peut être moins efficace que la sonde standard. Les résultats favorisent l'idée qu'un neurone peut être étudié opérationnellement comme composant observable et qu'une sonde peut en approximer le comportement sous contraintes.

Ils ne démontrent pas que le neurone est universellement un cas particulier de sonde, que chaque sonde peut apprendre le fonctionnement de chaque neurone, ni qu'une composition de sondes remplace exactement un système complet. La fidélité dépend du budget de paramètres, des données d'observation, du domaine et de la profondeur de composition. La prochaine preuve la plus décisive serait une expérience à budget strictement égal, sur une classe de neurones plus large, avec test shifté préenregistré et remplacement autonome de tous les composants sans conserver de lecteur source.

A Correctif d'intégrité et résultats frais v1.2

Statut de cette annexe. Cette annexe a été rédigée après les exécutions fraîches v1.2 et remplace toute qualification antérieure trop forte des essais v1.1. Les résultats anciens restent présents pour la traçabilité, mais ne sont pas fusionnés dans les tableaux v1.2. Le dossier source `NGeGenBrain_observation_formalisme_full_0.tex` a été conservé intact et son SHA-256 vérifié contre la copie employée. La sonde d'expérience est bien la famille RBF définie dans `formalisme_sonde_adaptative` c'est-à-dire une extension paramétrée de l'opérateur d'observation de la théorie, et non un changement silencieux du formalisme de base.

A.1 Correction d'admissibilité des pilotes v1.1

L'audit final du code v1.1 a montré que le worker unifié accessible au rôle d'imitation exposait le code de la classe/activation du MLP cible employé dans une autre condition. Même si aucun accès aux poids du neurone cible n'a été démontré, cette exposition du code du mécanisme cible enfreint la règle rouge stricte du protocole. Les scores d'imitation v1.1 sont donc conservés comme résultats historiques calculés, mais requalifiés **non confirmatoires et invalides pour une affirmation d'isolation stricte**. La composition v1.1 a été interrompue dès cette découverte et aucun tableau final n'en est rapporté. La classification v1.1 réutilisait en outre les graines du banc principal ; elle est un rejeu/audit, pas une réplication indépendante. Les décisions et artefacts sont conservés dans `audit/limitations_admissibilite_v1_1.md` ; les tableaux v1.2 ci-dessous proviennent d'une exécution fraîche avec capsules de code séparées.

A.2 Isolation v1.2 et préenregistrement

Avant l'exécution, les SHA-256 de 17 fichiers (deux sources théoriques, formalisation adaptative, contrôleur/oracle, protocole, workers et bibliothèques par rôle) ont été gelés dans `audit/strict_isolation_v1_2_preexecution_hashes.json`. La vérification finale retrouve **17/17 empreintes identiques**. Un test de fumée jetable a passé 13/13 assertions d'interface et de permissions ; ces données de fumée ne figurent dans aucun résultat scientifique.

Les rôles ont reçu des capsules logicielles distinctes sous identités OS différentes. En particulier, le rôle imitation ne reçoit qu'un régresseur RBF générique et les observations autorisées $(x, N(x))$; le rôle composant ne reçoit que les entrées d'apprentissage et une colonne d'activation ; seul le rôle enseignant accède au constructeur et aux poids initiaux/entraînés de l'enseignant ; l'évaluateur produit les prédictions gelées sans pouvoir lire les labels de test. Le contrôle d'accès s'exécute réellement sous chaque identité via `runuser`. Les modes et tests d'accès ont réussi, mais ne garantissent pas l'absence absolue de tout canal covert possible dans un environnement local.

Les données de classification ont été régénérées à partir des graines `20261121-20261123` ; les partitions utilisent les graines `1501, 1607, 1717`. Le cas réel v1.2 est la tâche binaire Wine (classe 0 contre classes 1/2, 178 exemples, 13 variables), et ne constitue ni un test médical ni un cas de déploiement. Le benchmark réel multiclasses digits décrit plus haut demeure un résultat historique séparé : il n'est pas réutilisé dans les moyennes confirmatoires v1.2 ni présenté comme exécuté dans les capsules v1.2.

A.3 Classification sur quatre tâches, partitions fraîches

Il y a **48 évaluations** (4 tâches × 3 graines × 4 méthodes) et 13 392 lignes de prédictions test gelées. Chaque modèle a produit sa prédiction sous l'identité d'inférence avant l'ouverture des labels par le contrôleur de score. Les douze contrôles de permissions et les douze contrôles de séparation des partitions passent ; aucun chevauchement exact de hachage de ligne entre train, validation et test n'est détecté dans les douze partitions.

Méthode	Exactitude	F1	ROC-AUC	Log-loss	Brier
RBF fixe	90.14 ± 4.28	89.15 ± 4.92	0.9636 ± 0.0278	0.340 ± 0.109	0.1001 ± 0.0381
Sonde adaptative A	95.35 ± 2.48	94.98 ± 2.86	0.9797 ± 0.0225	0.182 ± 0.079	0.0466 ± 0.0225
Sonde B, taux méta-appris	96.20 ± 2.50	96.02 ± 2.55	0.9816 ± 0.0236	0.136 ± 0.094	0.0348 ± 0.0237
MLP de référence	95.28 ± 2.95	95.22 ± 3.01	0.9797 ± 0.0212	0.155 ± 0.101	0.0413 ± 0.0269

TABLE 13 – Moyenne ± écart-type descriptif sur les 12 lignes tâche-graines de chaque méthode. Ces écarts-types mélangent aussi la difficulté entre tâches ; ils ne sont pas des intervalles de confiance. Exactitude et F1 sont exprimés en points de pourcentage.

Tâche	RBF fixe	Sonde A	Sonde B	MLP
two_moons	86.30 ± 2.67	94.72 ± 2.10	97.59 ± 0.42	93.52 ± 1.25
circles	91.11 ± 1.21	94.63 ± 0.16	94.54 ± 0.16	94.44 ± 0.28
xor_product	88.70 ± 2.64	93.89 ± 1.69	93.61 ± 1.44	93.15 ± 0.42
Wine binaire	94.44 ± 5.56	98.15 ± 3.21	99.07 ± 1.60	100.00 ± 0.00

TABLE 14 – Exactitude moyenne en pourcentage ± écart-type sur les trois graines de chaque tâche.

La sonde adaptative A dépasse le contrôle RBF fixe sur les quatre tâches de ces partitions. B est la meilleure méthode en exactitude macro moyenne sur ces douze évaluations, mais la différence avec A ou le MLP n'est pas une preuve générale de supériorité : seulement trois graines sont utilisées par tâche, Wine est petit et la condition B garde l'architecture RBF ainsi qu'un schéma de mise à jour prédéfini. B apprend quatre taux de groupe par hypergradients sur train/validation, initialisés de façon symétrique à 0.015 ; il n'invente pas un optimiseur depuis zéro.

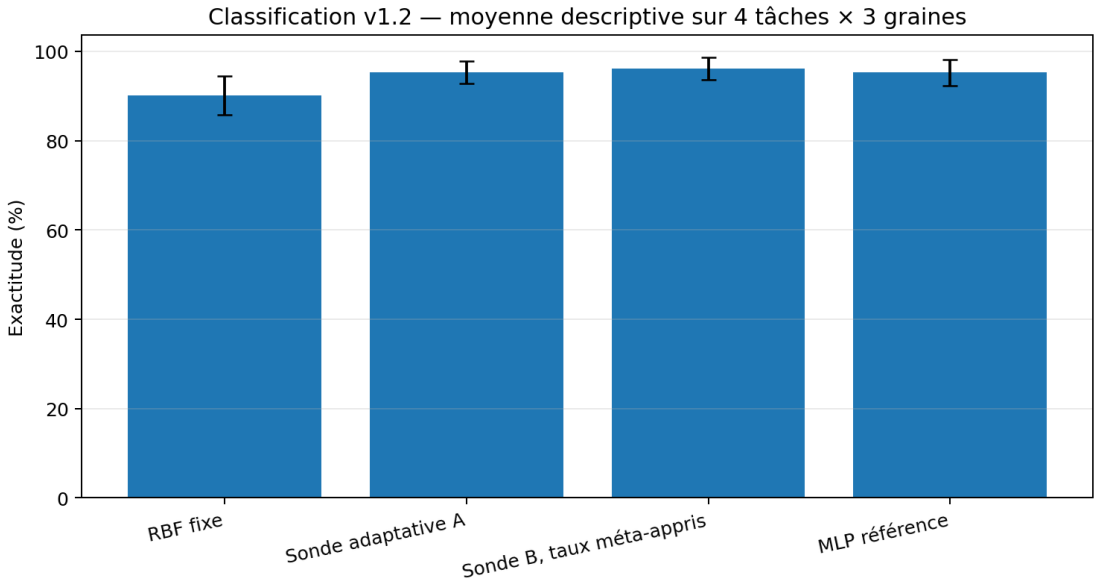


FIGURE 9 – Exactitude macro descriptive des méthodes de classification v1.2. Les barres d'erreur indiquent l'écart-type entre douze lignes tâche-graines, pas une incertitude populationnelle indépendante.

A.4 Imitation boîte noire de neurones isolés

Neuf cibles artificielles inédites, réparties entre trois familles d'activation (ReLU, sigmoïde, tanh), sont chacune interrogées sous trois budgets (64, 256, 1024 paires entrée-sortie). Pour chaque cible-budget, trois initialisations de sonde sont ajustées, soit **81 ajustements** sur **27 cibles-budgets**. Chaque ajustement est évalué sur 4 000 entrées de test (324 000 prédictions). Zéro chevauchement exact de hachages d'entrée train/test n'est détecté dans les 27 items. Les huit contrôles d'accès de cette condition passent.

Activation cible	Paires	MAE moyenne	RMSE moyenne	R^2 moyen
ReLU	64	0.08091	0.11097	0.98039
ReLU	256	0.06454	0.08688	0.98738
ReLU	1024	0.06442	0.08608	0.98854
Sigmoïde	64	0.01563	0.02150	0.99459
Sigmoïde	256	0.01306	0.01697	0.99636
Sigmoïde	1024	0.01309	0.01708	0.99660
Tanh	64	0.03917	0.05053	0.99106
Tanh	256	0.02924	0.03846	0.99488
Tanh	1024	0.03518	0.04363	0.99335

TABLE 15 – Moyennes sur neuf mesures (3 cibles par famille × 3 initialisations de sonde) par activation-budget. L'imitation est bonne sur ce domaine artificiel limité ; la MAE de tanh/ReLU n'est pas monotone avec le budget, donc le gain n'est pas strictement monotone. Les intervalles de confiance clusterisés par cible sont fournis dans le CSV dédié.

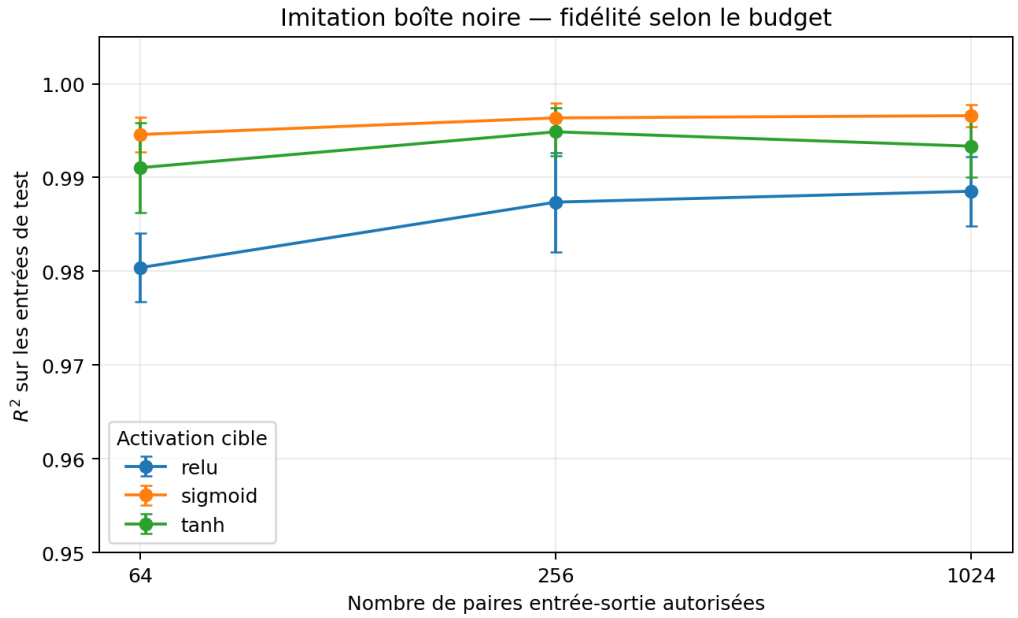


FIGURE 10 – Fidélité R^2 selon le budget d'observation sur les entrées tenues à part.

Ces résultats soutiennent H2 uniquement pour la famille de cibles définie dans le protocole : neurones artificiels simples à entrées bidimensionnelles, trois activations, domaine d'entrée contrôlé. Ils ne prouvent ni imitation d'un neurone arbitraire, ni équivalence exacte ; une valeur élevée de R^2 n'exclut pas des erreurs localisées. Les paramètres et formules de cibles ne sont pas présents dans la capsule accessible au rôle imitation ; seul le lot opaque d'observations autorisées est donné au worker.

A.5 Remplacement et composition de composants

Six réseaux enseignants (deux tâches × trois graines) sont entraînés. Quatre-vingt-seize sondes de composant (16 par réseau enseignant) sont apprises séparément à partir des entrées d'entraînement et d'une seule colonne d'activation chacune. Dix-huit mesures finales sont faites après remplacement de 1, 4 ou 16 unités cachées. Les 14 contrôles de permissions et 6 contrôles de partition passent. Le lecteur de sortie original est volontairement conservé : ces tests ne sont pas une reconstruction autonome.

Tâche	Unités remplacées	Exactitude enseignant	Exactitude composée	Écart absolu moyen des logits
two_moons	1	95.74 ± 1.70	94.91 ± 2.36	0.08270 ± 0.04510
two_moons	4	95.74 ± 1.70	94.44 ± 1.94	0.22008 ± 0.07578
two_moons	16	95.74 ± 1.70	90.56 ± 1.55	0.65458 ± 0.13073
Wine binaire	1	98.15 ± 1.60	100.00 ± 0.00	0.08337 ± 0.00192
Wine binaire	4	98.15 ± 1.60	99.07 ± 1.60	0.31228 ± 0.11348
Wine binaire	16	98.15 ± 1.60	100.00 ± 0.00	1.08239 ± 0.14560

TABLE 16 – Moyenne ± écart-type sur trois graines pour chaque tâche. Une exactitude égale ou meilleure ne signifie pas imitation des logits ou des activations.

Tâche	MAE activation	RMSE activation	R^2 activation
two_moons	0.0600 ± 0.0340	0.0768 ± 0.0420	0.9818 ± 0.0160
Wine binaire	0.1564 ± 0.0603	0.2196 ± 0.0788	0.9018 ± 0.0829

TABLE 17 – Fidélité locale des activations sur des entrées tenues à part : les métriques sont d'abord moyennées sur 16 unités par enseignant, puis résumées sur trois graines.

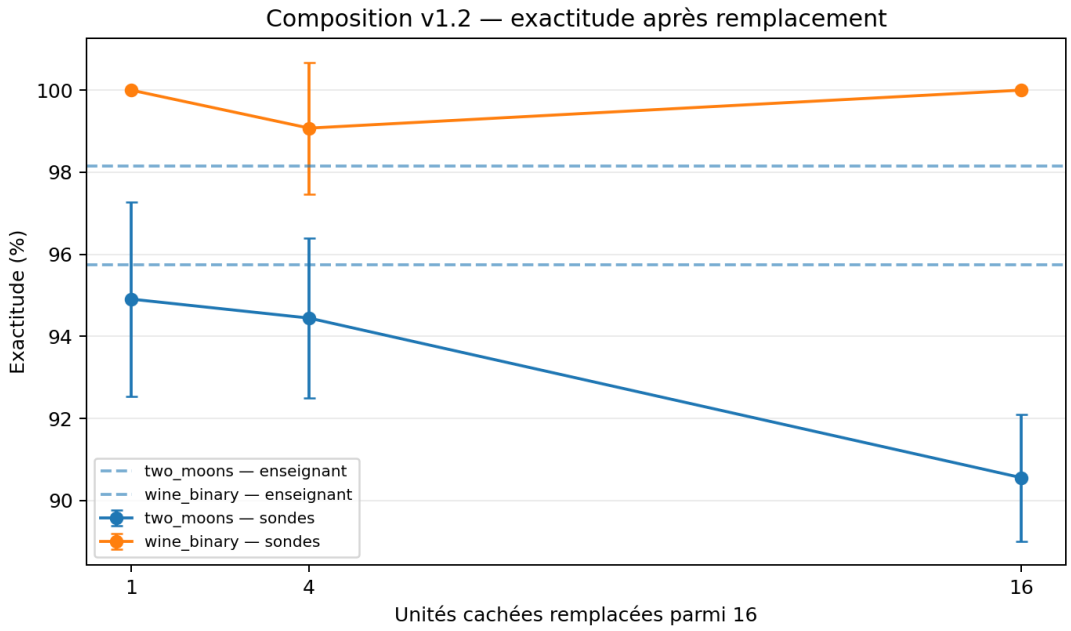


FIGURE 11 – Exactitude après remplacement de composants. Le trait enseignant donne l'exactitude du réseau original ; les intervalles sont des écarts-types sur trois graines.

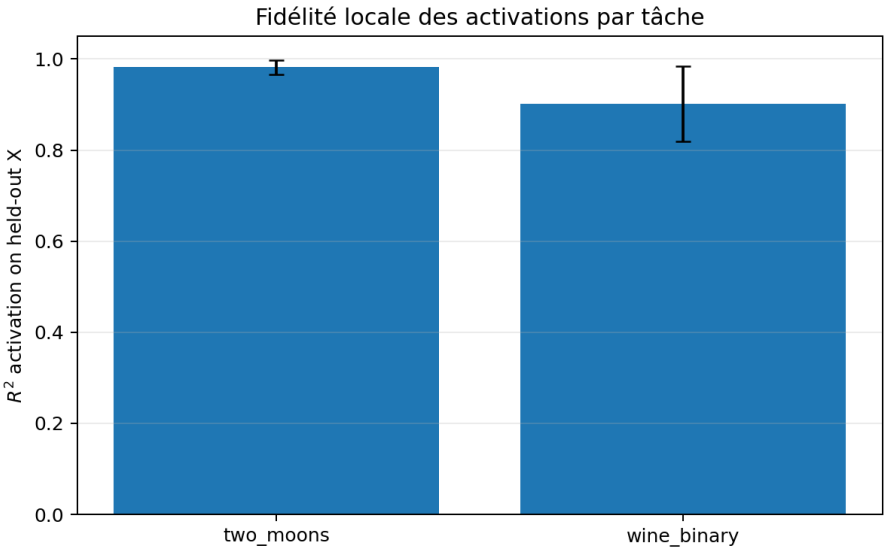


FIGURE 12 – Fidélité moyenne des activations sur données de test.

Sur two_moons, l'exactitude diminue de 95.74% pour l'enseignant à 90.56% quand 16 unités sont remplacées ; l'écart moyen des logits passe de 0.0827 (unité remplacée) à 0.6546 (16 unités). Sur Wine, l'exactitude reste élevée, même à 16 unités remplacées, alors que l'écart moyen absolu des logits atteint 1.0824 et le R^2 moyen des activations est autour de 0.902. La conservation de la décision finale sur ce petit test n'est donc pas une mesure suffisante de fidélité fonctionnelle.

A.6 Audit d'intégrité, artefacts et verdict

Le contrôle de bout en bout rapporte `PASS_WITH_LIMITATIONS`. Les 17 fichiers gelés sont inchangés, les deux copies des sources obligatoires correspondent octet par octet aux originaux, les CSVs ont les nombres de lignes attendus (48 mesures de classification, 81 mesures d'imitation, 324 000 prédictions d'imitation, 18 mesures de composition et 96 lignes de fidélité locale), les clés naturelles sont uniques, toutes les valeurs numériques évaluées sont finies et les 231 checkpoints peuvent être chargés avec des tenseurs finis. Les prédictions de probabilité sont dans $[0, 1]$ et les classes exportées correspondent au seuil appliqué. Les hachages des fichiers finaux sont recensés dans le manifeste.

Les contrôles réussis réduisent nettement le risque de fuite par fichiers et de corruption des artefacts, mais ils ne sont pas une preuve d'absence absolue de canal caché. Le paquet ne présente donc jamais l'audit comme une garantie mathématique. Les CSV d'intervalles à 95% sont descriptifs : classification et composition utilisent trois graines par tâche, imitation utilise trois cibles par famille et agrège les initialisations de sonde par cible ; ces petits effectifs interdisent les affirmations de généralité forte.

Réponses aux hypothèses.

- **H1 – Apprentissage de tâche :** soutenue pour les quatre tâches classées dans v1.2 ; adaptation améliore le contrôle RBF fixe, mais n'établit pas une supériorité générale sur un MLP.
- **H2 – Imitation d'un neurone :** soutenue pour les trois familles de neurones artificiels simples testées, avec une forte fidélité empirique sur le domaine évalué ; non démontrée hors de ce domaine.
- **H3 – Généralisation :** soutenue seulement sur les entrées indépendantes prévues par ce protocole. Les tests de décalage de distribution ne sont pas inclus dans la v1.2 confirmatoire.
- **H4 – Composition :** partiellement soutenue. Le remplacement opérationnel fonctionne, mais les erreurs d'activation/logits s'accumulent et le résultat dépend du système.
- **H5 – Généralité :** non établie ; quatre tâches de classification et trois familles de neurones simples restent une couverture restreinte.

— **H6 – Neurone comme cas particulier de sonde :** les données démontrent une famille de sondes adaptatives qui approxime certaines fonctions neuronales observées. Elles ne démontrent pas une équivalence mathématique universelle ni que tous les neurones sont des sondes au sens de la théorie originale.

Les livrables complétés comprennent les sources, scripts de workers séparés, configurations/protocoles, résultats par graine, prédictions gelées, intervalles descriptifs, journaux, audits, 231 checkpoints, inventaire et empreintes SHA-256. Les commandes et la structure sont documentées dans le README. Les résultats v1.1 non confirmatoires sont conservés explicitement, sans les mélanger aux résultats v1.2.